

Price Disparity between Healthy and Processed Foods as a Predictor of Obesity Rates in the USA: An Analysis with USDA and BRFSS Public Data

Evandro Barreto¹
and
Kaiky de Souza Lima¹

Universidade Tecnológica Federal do Paraná, Brazil
{evandrobarreto, kaiky}@alunos.utfpr.edu.br

Keywords: obesity, food prices, machine learning, classification, supervised learning, BRFSS, USDA, data mining

1. INTRODUCTION

A obesidade constitui um dos maiores desafios contemporâneos de saúde pública, sendo substancialmente agravada por variáveis macroeconômicas. Populações expostas à vulnerabilidade econômica tendem a encontrar barreiras de custo no acesso a alimentos de elevado valor nutricional, recorrendo a alternativas ultraprocessadas, energeticamente densas e nutricionalmente pobres [?].

Embora a relação entre custo alimentar e obesidade seja intuitivamente sugerida na literatura, a principal lacuna metodológica reside na integração sistemática de bases de dados epidemiológicas e econômicas díspares para atestar esse fenômeno de forma quantitativa e replicável. Este artigo aborda essa lacuna por meio de um pipeline analítico preditivo que combina dados públicos do USDA e do CDC/BRFSS.

As seguintes perguntas de pesquisa orientam o estudo:

—**P1:** Existe relação mensurável e estatisticamente significativa entre o custo de alimentos saudáveis (preço de frutas e vegetais) e a faixa de renda da população com os índices de obesidade nos estados norte-americanos?

As hipóteses testadas são:

—**H1:** A elevação sustentada nos preços médios de frutas e vegetais está positivamente associada ao aumento das taxas de obesidade.

—**H2:** Categorias específicas de grupos de alimentos apresentam variações de preço com impacto diferenciado nos índices de obesidade.

—**H3:** Populações com menor faixa de renda apresentam maiores índices de obesidade, sendo a renda um fator moderador na relação entre custo de alimentos saudáveis e risco de obesidade.

O restante do artigo está organizado da seguinte forma: a Seção 2 apresenta os trabalhos relacionados; a Seção 3 descreve os conjuntos de dados utilizados; a Seção 4 detalha o pipeline metodológico; a Seção 5 apresenta os experimentos e resultados; e a Seção 6 conclui o artigo.

Table I. Características dos datasets utilizados

Atributo	BRFSS (CDC)	FAHMAP (USDA)
Granularidade	Estado / ano	Região / mês
Período	TODO	TODO
Nº de registros	TODO	TODO
Variável-alvo	Taxa de obesidade (%)	–

2. RELATED WORK

Diversos estudos investigaram a relação entre ambiente alimentar, renda e obesidade. [?] demonstraram que o custo relativo de alimentos saudáveis versus ultraprocessados é um preditor significativo de escolhas alimentares em populações de baixa renda. [?] utilizaram dados longitudinais do BRFSS para identificar tendências temporais de obesidade associadas a fatores socioeconômicos.

Do ponto de vista metodológico, abordagens de aprendizado de máquina têm sido aplicadas à predição de riscos de saúde pública [?]. No entanto, poucos trabalhos integram dados econômicos de preços regionais de alimentos com indicadores epidemiológicos de obesidade em um pipeline analítico unificado, o que representa a principal contribuição deste estudo.

3. DATA

3.1 Dataset 1: Nutrition, Physical Activity and Obesity (CDC/BRFSS)

O Behavioral Risk Factor Surveillance System (BRFSS) é um sistema de vigilância em saúde conduzido pelo CDC (Centers for Disease Control and Prevention). O dataset utilizado contém séries temporais e recortes geográficos com indicadores de obesidade, consumo de frutas e vegetais e atividade física de adultos americanos.

As principais variáveis de interesse incluem: taxa de obesidade por estado e ano, estratificada por faixa de renda, nível educacional, sexo e etnia.

3.2 Dataset 2: Food-at-Home Monthly Area Prices (USDA)

O dataset do USDA monitora mensalmente os preços regionais de gêneros alimentícios domiciliares, desagregado por área geográfica. Permite análise temporal das oscilações de custo e cruzamento geoespacial com os dados de saúde do BRFSS.

As principais variáveis de interesse incluem: preço médio mensal por categoria de alimento (frutas, vegetais, proteínas, ultraprocessados) por região geográfica.

3.3 Integração dos Dados

A integração entre os dois datasets é realizada por meio de chave composta (**estado**, **ano**), permitindo o alinhamento temporal e geoespacial entre as variáveis de preço e os indicadores de saúde. A Tabela I sumariza as características principais dos datasets.

4. METHODOLOGY

O pipeline analítico proposto é composto por duas etapas sequenciais, conforme ilustrado na Figura 0??.

4.1 Pré-processamento

As etapas de pré-processamento incluem: (i) remoção de registros com valores ausentes nas variáveis de interesse; (ii) normalização dos preços pelo índice de inflação (CPI); (iii) agregação temporal dos preços mensais em médias anuais por estado; e (iv) codificação de variáveis categóricas (faixa de renda, região geográfica).

4.2 Etapa 1: Classificação

Na primeira etapa, um modelo de classificação verifica se a variação nos preços de alimentos saudáveis exerce influência estatisticamente relevante sobre as taxas de obesidade. A variável-alvo é binarizada com base na mediana das taxas estaduais de obesidade (*alto* vs. *baixo*).

Os algoritmos avaliados incluem: Regressão Logística, Random Forest e Gradient Boosting (XGBoost). A seleção de hiperparâmetros é realizada via validação cruzada estratificada com $k = 5$ folds.

4.3 Etapa 2: Regressão

Confirmada a relação na Etapa 1, um modelo de regressão quantifica a magnitude do impacto de cada categoria de preço sobre as taxas de obesidade. Os algoritmos avaliados incluem: Regressão Linear com regularização (Ridge/Lasso), Random Forest Regressor e XGBoost Regressor.

4.4 Análise do Fator Moderador: Renda

Em paralelo, é conduzida uma análise estratificada por faixa de renda para investigar se a capacidade econômica do indivíduo atua como fator moderador na relação entre custo de alimentos saudáveis e risco de obesidade.

5. EXPERIMENTAL EVALUATION PLAN

5.1 Configuração Experimental

Os experimentos serão conduzidos em ambiente Python 3.x, utilizando as bibliotecas `pandas`, `scikit-learn`, `xgboost` e `matplotlib`. O código e os notebooks estão disponíveis publicamente em: <https://github.com/KaikyLima/food-price-obesity-analysis>.

5.2 Métricas de Avaliação

Para a tarefa de **classificação**, serão utilizadas as métricas: Acurácia, Precisão, Revocação, F1-score e AUC-ROC.

Para a tarefa de **regressão**, serão utilizadas: RMSE (Root Mean Squared Error), MAE (Mean Absolute Error) e R^2 .

5.3 Hipóteses e Experimentos Planejados

- Experimento 1 (H1):** Treinar classificadores com e sem as features de preço de frutas/vegetais e comparar o desempenho para verificar o poder preditivo dessas variáveis.
- Experimento 2 (H2):** Analisar a importância de features (*feature importance*) nos modelos de ensemble para identificar quais categorias de alimentos têm maior impacto na taxa de obesidade.
- Experimento 3 (H3):** Stratificar os dados por faixa de renda e comparar os modelos treinados em cada estrato, avaliando se a relação preço–obesidade é modulada pela renda.

5.4 Resultados Preliminares

Esta seção será expandida com os resultados dos experimentos. A análise exploratória inicial indicou [TODO: inserir observação preliminar].

6. CONCLUSION

Este artigo apresentou um pipeline analítico para investigar a relação entre a disparidade de preços de alimentos saudáveis e ultraprocessados e os índices de obesidade nos estados norte-americanos, utilizando dados públicos do USDA e do CDC/BRFSS. A abordagem proposta combina técnicas de classificação e regressão supervisionadas, com análise complementar do papel moderador da renda. Os resultados esperados têm potencial de contribuir com evidências quantitativas para políticas públicas de saúde alimentar.

Como trabalhos futuros, pretende-se incorporar variáveis adicionais de acesso a alimentos (*food deserts*), expandir a análise para recortes temporais mais recentes e investigar modelos de aprendizado profundo para séries temporais.

REFERENCES