

Price Disparity between Healthy and Processed Foods as a Predictor of Obesity Rates in the USA: An Analysis with USDA and BRFSS Public Data

Evandro Barreto¹

and

Kaiky de Souza Lima¹

Universidade Tecnológica Federal do Paraná, Brazil
{evandrobarreto, kaiky}@alunos.utfpr.edu.br

Abstract. Obesity is one of the most pressing global public health challenges, with socioeconomic factors playing a decisive role in its prevalence. This study investigates whether the price disparity between healthy and ultra-processed foods is a statistically significant predictor of obesity rates across American states. We integrate two public datasets: the Behavioral Risk Factor Surveillance System (BRFSS), provided by the CDC, which contains time-series indicators of obesity, fruit and vegetable consumption, and physical activity among American adults; and the Food-at-Home Monthly Area Prices dataset, provided by the USDA, which monitors regional monthly prices of household food items disaggregated by geographic area. A two-stage predictive analytical pipeline is proposed: first, a classification model to assess whether variations in healthy food prices significantly influence obesity rates; second, conditional on that relationship, a regression model to quantify the magnitude of this impact. Additionally, income level is examined as a potential moderating factor in the relationship between food prices and obesity risk. We hypothesize that sustained increases in fruit and vegetable prices are positively associated with higher obesity rates, and that lower-income populations are disproportionately affected. This work is aligned with the topics of Classification, Supervised Learning, Machine Learning Applications, Data Mining Applications, and Time-Series Analysis.

CCS Concepts: • **Computing methodologies** → **Machine learning**; *Supervised learning*.

Keywords: obesity, food prices, machine learning, classification, supervised learning, BRFSS, USDA, data mining

1. INTRODUCTION

A obesidade constitui um dos maiores desafios contemporâneos de saúde pública, sendo substancialmente agravada por variáveis macroeconômicas.

Embora a relação entre custo alimentar e obesidade seja intuitivamente sugerida na literatura, a principal lacuna metodológica reside na integração sistemática de bases de dados epidemiológicas e econômicas díspares para atestar esse fenômeno de forma quantitativa e replicável. Este artigo aborda essa lacuna por meio de um pipeline analítico preditivo que combina dados públicos do USDA e do CDC/BRFSS.

As seguintes perguntas de pesquisa orientam o estudo:

- P1:** Existe relação mensurável e estatisticamente significativa entre o custo de alimentos saudáveis (preço de frutas e vegetais) e a faixa de renda da população com os índices de obesidade nos estados norte-americanos?

Copyright©2025 Permission to copy without fee all or part of the material printed in KDMiLe is granted provided that the copies are not made or distributed for commercial advantage, and that notice is given that copying is by permission of the Sociedade Brasileira de Computação.

As hipóteses testadas são:

- H1:** A elevação sustentada nos preços médios de frutas e vegetais está positivamente associada ao aumento das taxas de obesidade.
- H2:** Categorias específicas de grupos de alimentos apresentam variações de preço com impacto diferenciado nos índices de obesidade.
- H3:** Populações com menor faixa de renda apresentam maiores índices de obesidade, sendo a renda um fator moderador na relação entre custo de alimentos saudáveis e risco de obesidade.

2. RELATED WORK

Em desenvolvimento [?]

3. DATA

3.1 Dataset 1: Nutrition, Physical Activity and Obesity (CDC/BRFSS)

O Behavioral Risk Factor Surveillance System (BRFSS) é um sistema de vigilância em saúde conduzido pelo CDC (Centers for Disease Control and Prevention). O dataset utilizado contém séries temporais e recortes geográficos com indicadores de obesidade, consumo de frutas e vegetais e atividade física de adultos americanos.

As principais variáveis de interesse incluem: taxa de obesidade por estado e ano, estratificada por faixa de renda, nível educacional, sexo e etnia.

3.2 Dataset 2: Food-at-Home Monthly Area Prices (USDA)

O dataset do USDA monitora mensalmente os preços regionais de gêneros alimentícios domiciliares, desagregado por área geográfica. Permite análise temporal das oscilações de custo e cruzamento geoespacial com os dados de saúde do BRFSS.

As principais variáveis de interesse incluem: preço médio mensal por categoria de alimento (frutas, vegetais, proteínas, processados) por região geográfica.

3.3 Integração dos Dados

A integração entre os dois datasets é realizada por meio de chave composta (**estado**, **ano**), permitindo o alinhamento temporal e geoespacial entre as variáveis de preço e os indicadores de saúde. A Tabela I sumariza as características principais dos datasets.

Table I. Características dos datasets utilizados

Atributo	BRFSS (CDC)	FAHMAP (USDA)
Granularidade	Estado / ano	Região / mês
Período	2012–2018	2012–2018
Nº de registros	110.880	1.020.600
Variável-alvo	Taxa de obesidade (%)	–

4. METHODOLOGY

O pipeline analítico é composto por três etapas: pré-processamento e integração dos dados, análise exploratória e correlacional, e — como trabalho futuro — modelagem preditiva supervisionada.

4.1 Pré-processamento e Integração

Os dados do BRFSS foram filtrados para registros com indicador de obesidade válido, estratificados por faixa de renda e agregados por estado e ano. Os dados do USDA foram agregados de granularidade mensal para médias anuais por região geográfica. A integração entre os dois datasets foi realizada por meio de chave composta (**região**, **ano**), resultando em um dataset analítico unificado com variáveis de preço e indicadores de saúde alinhados temporalmente. Todo o pipeline foi implementado em Python utilizando **pandas** e **DuckDB** para consultas SQL sobre os dados brutos.

4.2 Análise Exploratória e Correlacional

Foram construídas duas variáveis derivadas principais: *Price_Healthy*, o preço médio de alimentos saudáveis (frutas e vegetais), e *Price_Ratio*, a razão entre o preço de alimentos saudáveis e ultra-processados. A relação entre essas variáveis e as taxas de obesidade foi investigada por meio do coeficiente de correlação de Pearson, calculado separadamente para cada região geográfica (Nordeste, Centro-Oeste, Sul e Oeste). A influência da faixa de renda foi avaliada por meio de correlação entre uma codificação ordinal das faixas de renda e as taxas de obesidade, além de análise temporal estratificada por grupo de renda.

4.3 Plano de Modelagem Preditiva (Trabalho Futuro)

Em desenvolvimento

5. EXPERIMENTAL EVALUATION PLAN

5.1 Configuração Experimental

Em desenvolvimento

5.2 Métricas de Avaliação

Em desenvolvimento

5.3 Hipóteses e Experimentos Planejados

Em desenvolvimento

5.4 Resultados Preliminares

Em desenvolvimento

6. RESULTS AND DISCUSSION

Em desenvolvimento.

7. LIMITATIONS AND THREATS TO VALIDITY

Em desenvolvimento.

8. CONCLUSION

Em desenvolvimento

REFERENCES